

基于机器学习的川中地区雷口坡组三段二亚段泥质灰岩储层分布预测

任 杉¹, 宋金民^{1*}, 李柯然¹, 杨 迪¹, 叶玥豪¹, 李泽奇¹, 王 斌¹,
邵兴鹏¹, 周佳庆¹, 杨绍海¹, 闫春桥¹, 金 鑫¹, 郭嘉欣¹, 刘树根^{1,2}

1. 油气藏地质及开发工程全国重点实验室(成都理工大学), 成都 610059;

2. 西华大学, 成都 610039

[摘要] 四川盆地中部 CT1 井雷口坡组三段二亚段(简称雷三²亚段)泥质灰岩储层在近期取得工业性气流, 显示出良好的勘探前景。目前对泥质灰岩储层的测井响应机制与预测模型的研究较为薄弱。通过川中地区雷三²亚段的岩心描述、薄片观察与测井响应特征总结, 建立了基于测井数据的长短期记忆网络(LSTM)的机器学习模型; 对泥质灰岩进行岩性识别, 结合单因素矿物含量分析及沉积相特征, 实现泥质灰岩储层“点-线-面”多元综合预测。研究结果表明, 雷三²亚段以灰岩、泥质灰岩、白云岩及膏盐岩为主, 泥质灰岩储层储集空间以纳米-微米级的孔隙和微裂缝为主, 为典型的低孔低渗型储层, 储层厚度 40~130 m。对比 CIFLog 软件计算结果和镜下薄片鉴定结果, LSTM 模型预测结果的精确度达到(87.3±0.5)%。预测结果显示, 泥质灰岩储层主要分布在西充、南充及仪陇地区, 厚 80~120 m, 呈“中厚边薄”的特征, 为优势勘探区; 中江、资阳、安岳及合川地区储层厚度 60~80 m, 为潜在勘探区。本次研究为川中地区雷三²亚段泥质灰岩储层的油气勘探提供参考。

[关键词] 川中地区; 雷三²亚段; 泥质灰岩储层; 机器学习; 预测模型

[分类号] P618.13;TE311;TP18

[文献标志码] A

Prediction of the distribution of marly limestone reservoirs in the second sub-member of the third member of the Leikoupo Formation, central Sichuan Basin, based on machine learning

REN Shan¹, SONG Jinmin^{1*}, LI Keran¹, YANG Di¹, YE Yuehao¹, LI Zeqi¹, WANG Bin¹,
SHAO Xingpeng¹, ZHOU Jiaqing¹, YANG Shaohai¹, YAN Chunqiao¹, JIN Xin¹,
GUO Jiaxin¹, LIU Shugen^{1,2}

收稿日期: 2025-07-29; 改回日期: 2025-09-07。 责任编辑: 甘娟娟。

基金项目: 国家科技重大专项(2025ZD1400403); 国家自然科学基金面上项目(42572132, 41872150)。

第一作者: 任杉(2001—), 女, 硕士研究生, 研究方向: 机器学习在碳酸盐岩储层中的应用, E-mail: raiten@foxmail.com。

*通信作者: 宋金民(1983—), 男, 博士, 教授, 研究方向: 碳酸盐岩沉积储层, E-mail: songjinmin2012@cdut.edu.cn。

引用格式: 任杉, 宋金民, 李柯然, 等, 2025. 基于机器学习的川中地区雷口坡组三段二亚段泥质灰岩储层分布预测 [J]. 成都理工大学学报(自然科学版), 52(5): 914—930.

Ren S, Song J M, Li K R, et al., 2025. Prediction of the distribution of marly limestone reservoirs in the second sub-member of the third member of the Leikoupo Formation, central Sichuan Basin, based on machine learning [J]. Journal of Chengdu University of Technology (Science & Technology Edition), 52(5): 914—930.

1. State Key Laboratory of Oil and Gas Reservoir Geology and Exploitation, Chengdu University of Technology, Chengdu 610059, China;
2. Xihua University, Chengdu 610039, China

Abstract: Recently, an industrial gas flow has been obtained from the second sub-member of the third member of the Leikoupo Formation (Le_{32}) at Well CT1 in the central Sichuan Basin, indicating favorable exploration prospects for marly limestone reservoirs. However, research on well-logging response mechanisms and predictive modeling for such reservoirs remains limited. This study integrates core descriptions, thin-section petrography, and a well-log response analysis to characterize the lithological features of the Le_{32} sub-member. A long short-term memory (LSTM) machine learning model was established using well-log data for lithofacies identification of marly limestone. By integrating a single-factor mineral content analysis and sedimentary facies characteristics, a multi-scale predictive framework (point-line-surface) was constructed to forecast marly limestone reservoirs. The results show that the Le_{32} sub-member is primarily composed of limestone, marly limestone, dolomite, and gypsum salt rocks. The marly limestone reservoir is characterized by nanoscale to micrometer-scale pores and microfractures, indicating a typical low-porosity, low-permeability system, with reservoir thickness ranging from 40 to 130 m. Compared with CIFLog software calculations and petrographic identifications, the LSTM model achieved a prediction accuracy of $(87.3 \pm 0.5)\%$. Spatial prediction results indicate that the reservoir's thickness ranges from 80 to 120 m in the Xichong, Nanchong, and Yilong areas, which are favorable for exploration. In contrast, Zhongjiang, Ziyang, Anyue, and Hechuan exhibit reservoir thicknesses of 60 to 80 m, suggesting potential exploration targets. This study provides useful a reference for the hydrocarbon exploration of marly limestone reservoirs in the Le_{32} sub-member of the central Sichuan Basin.

Key words: central Sichuan area; Le_{32} ; marly limestone reservoir; machine learning; prediction model

四川盆地中三叠统雷口坡组具有丰富的天然气资源量,是埋藏最浅的碳酸盐岩产层(尹宏等, 2024),发育常规和非常规2类天然气资源(谢武仁等, 2024)。自20世纪70年代起,历经60余年的勘探,累计探明天然气地质储量为 $582.93 \times 10^8 \text{ m}^3$ (辛勇光等, 2022)。2019年在川中地区CT1井雷口坡组三段二亚段(以下简称雷三²亚段)泥质灰岩储层内取得重大勘探突破,测试日产气 10.87 m^3 ,储量规模达 $(2\,000 \sim 3\,000) \times 10^8 \text{ m}^3$ (田瀚等, 2021; 孙豪飞等, 2021; 汪泽成等, 2023)。泥质灰岩储层多分布于蒸发潟湖内,为蒸发岩封盖、源储一体的非常规油气藏(张豪等, 2024)。

川中地区雷三²亚段岩性包含灰岩、泥质灰岩、白云岩与膏盐岩(孙豪飞等, 2021; 汪泽成等, 2023; 张豪等, 2024)。泥质灰岩埋深介于 $2\,000 \sim 4\,000 \text{ m}$,厚 $40 \sim 130 \text{ m}$,面积约 $40\,000 \text{ km}^2$ (汪泽成等, 2023),兼有烃源岩和储层的功能(张建勇等, 2023);储集空间以纳米-微米级无机孔、有机质孔和裂缝为主,孔隙度为 $2.00\% \sim 8.51\%$,渗透率为 $(0.007\,6 \sim 1.680\,0) \times 10^{-3} \mu\text{m}^2$,为低孔低渗储层(张豪等, 2024);生烃强度为 $(4 \sim 12) \times 10^8 \text{ m}^3/\text{km}^2$,

估算生烃量为 $25 \times 10^{12} \text{ m}^3$ (田瀚等, 2021),是海相非常规油气勘探的新类型。有学者利用地震波形指示模拟及反演,预测出川中地区雷三²亚段泥质灰岩储层的厚度在 $30 \sim 60 \text{ m}$,面积分布达 124 km^2 (张豪等, 2023)。

但泥质灰岩储层与膏盐岩波阻抗差异较小,单层厚度较薄,直接利用传统地震属性和波阻抗反演难以实现精细预测(张豪等, 2024)。虽然自动分析岩性软件(如Avizo, PerGeos等)逐渐被引入岩性预测(Kuang et al., 2021),但是自动化分析软件多依赖人机交互,对专业经验要求度高,导致岩性预测结果差异较大(秦小林等, 2025)。随着人工智能等技术的不断发展,数据驱动的机器学习模型与测井数据结合的方法逐步应用到岩性预测中。提升树(boosting tree)、决策树(decision tree)、支持向量机(support vector machine, SVM)等算法在准噶尔盆地玛北油田复杂砂砾岩储层中进行了尝试(江凯等, 2018)。梯度提升决策树(gradient boosting decision tree, GBDT)模型在花岗岩、千枚岩及角砾岩矿床预测中进行了探索(Zou et al., 2021; 谷宇峰等, 2021)。K-means算法

与合成少数类过采样技术(SMOTE)相结合在北海相砂岩等 9 类岩性的预测中也取得了较好的效果(罗仁泽等, 2023)。

机器学习算法已被应用于雷口坡组的研究, 主要涉及川西地区的岩性识别、储层裂缝预测和含气性预测(孔强夫等, 2020; 蒋旭东, 2021; 崔正伟, 2021)。比如图论聚类 and 最小临近算法在岩性识别方面的应用(孔强夫等, 2020); 二维经验模态算法、Teager-Kaiser 能量算子类方法、深度神经网络方法在含气性预测方面的探索(蒋旭东, 2021); 构造导向滤波与梯度结构张量(GST)算法判断在断层、裂缝预测中的应用(崔正伟, 2021)。但目前针对川中地区雷三²亚段泥质灰岩储层的机器学习预测, 尤其是基于海量测井数据的岩性识别方法则还未公开。另外, 前人多采用直接部署机器学习模型, 实现测井数据-岩性的“端-端”过程(Zeng et al., 2020; Kumar et al., 2022; Sun et al., 2025; Li et al., 2025), 未充分考虑沉积序列对模型预测的约束性(Li et al., 2019)。雷三²亚段发育于川中地区的局限台地沉积环境(阮蕴博等, 2022), 泥质灰岩储层呈薄层状产出, 岩性变化在纵向上表现出明显的旋回性和时序变化特征, 具有显著的时间序列依赖性, 即相邻层段的岩性组合往往存在可预测的前后关系, 更适用于能够有效捕捉长期依赖关系的模型(Liu et al., 2023; Zhang et al., 2024; Haritha et al., 2025)。相比于传统神经网络, 长短期记忆网络(LSTM)作为一种特殊的循环神经网络, 通过记忆门控机制保留前后深度点的信息, 捕捉沉积旋回中岩性变化的规律性, 具有记忆长期依赖信息、解决梯度消失问题的优势, 在预测过程中体现出对沉积序列的约束效果, 能够更准确地模拟测井数据中的时间序列变化规律。

本文以四川盆地川中地区雷口坡组三段二亚段为研究对象, 综合岩心描述、薄片观察及储层特征, 系统分析测井数据完整性、测井特征与岩性类型响应差异, 建立基于测井-岩性数据的长短时记忆循环神经网络模型(long short term memory, LSTM)岩性识别模型, 并与双向长短时记忆网络(BiLSTM)、卷积神经网络-长短时记忆网络(CNN-LSTM)、卷积神经网络-双向注意力机制-双向长短时记忆网络(CNN-BiAttention-BiLSTM)、传统机器学习方法即极端梯度提升

(eXtreme gradient boosting, XGBoost)、随机森林(random forest, RF)、支持向量机(support vector machine, SVM)和人工神经网络(artificial neural network, ANN)多种模型进行对比。通过 CIFLog 软件计算结果、岩心观察和薄片鉴定结果对模型进行验证。进一步结合单井预测、连井横向展布及平面展布, 引入四川盆地单因素空间分布规律, 实现川中地区雷三²亚段泥质灰岩非常规储层的点-线-面多元综合预测, 为下一步的油气勘探提供参考。

1 区域地质概况

中三叠世末期上扬子板块西缘为古特提斯洋东南侧的被动大陆边缘盆地, 周缘的深断裂转化为压剪性活动, 地壳收缩, 呈现边缘下陷内部上升的外压内张的特征(秦川, 2009)。受印支运动影响, 四川盆地整体抬升, 东部形成泸州古隆起和开江古隆起(汪泽成等, 2023), 西部则为凹陷, 呈现出东高西低、隆-坳相间的古地理格局(张本健等, 2023)。

中三叠世雷口坡沉积期, 上扬子板块发育蒸发-局限台地沉积环境, 总体为一套碳酸盐岩和蒸发岩共生沉积序列(图 1-A, B)(阮蕴博等, 2022)。雷口坡组厚度可达 1 000~1 200 m(宋晓波等, 2024), 根据岩性及电性特征, 自下而上划分为雷口坡组一段~雷口坡组四段(简称雷一段~雷四段)4 个段、9 个亚段(宋金民等, 2024)。川中地区雷三段厚度 200~400 m, 雷三段与下伏雷二段以自然伽马(GR)和电阻率骤降分界, 岩性从泥质白云岩转变为含泥质的灰岩(陈科贵等, 2014), 纵向上分为雷三¹亚段、雷三²亚段和雷三³亚段(图 1-C)。雷三¹亚段以膏盐岩、泥质白云岩为主, 为云坪、膏云坪微相, 电性以伽马降低、电阻率上升半幅点与雷三²亚段分层(图 1-C)。雷三²亚段主要为膏盐岩、泥质灰岩与灰岩互层, 以膏盐潟湖微相为主, 测井特征表现为电阻率升高、自然伽马值和声波时差值较高, 呈锯齿状(图 1-C)。上部雷三³亚段多为灰岩及白云岩, 以云坪、灰坪微相为主, 表现为自然伽马(GR)降低、电阻率上升的特征(孙豪飞, 2021)(图 1-C)。上覆的雷四段主要为泥-粉晶白云岩夹薄层石膏, 底部见泥质白云岩, 自然伽马值升高、声波时差值降低(刘树根等, 2019)。




图 1 川中地区雷三²亚段地质概况图

Fig. 1 Geological overview of Lei₃² in the central Sichuan area

(A) 四川盆地雷三²亚段沉积相展布图(修改自杨雨等, 2022); (B) 川中地区雷三²亚段沉积相分布图;
(C) 川中地区雷三²亚段地层综合柱状图


2 储层特征与测井响应特征

川中地区雷三²亚段总体发育灰岩、泥质灰岩、白云岩与膏盐岩。宏观岩心表现为灰黑色—深灰色富含有机质的泥晶灰岩(图 2-A)和泥质灰岩(图 2-B)及灰白色膏盐岩夹深灰色泥质白云岩(图 2-C)。显微镜下,雷三²亚段灰岩中黏土矿物体积分数较低,为 2%~25%,见少量方解石晶间孔,显示为含泥泥晶灰岩(图 2-D)。泥质灰岩中黏土矿物体积分数高,大于 25%,可见矿物晶间孔、粒间溶孔和有机质孔,局部泥质充填(图 2-E, F);含膏泥质灰岩少量发育,其内可见方解石脉(图 2-G)。部分膏盐岩沥青侵染,内部可见沿裂缝扩溶的溶孔(图 2-H)。雷三²亚段中

白云岩晶粒大小为粉晶—细晶,局部充填裂缝(图 2-I)。

川中地区雷三²亚段灰岩样品的孔隙度介于 0.10%~8.51%,渗透率介于(0.007 6~1.680 0)×10⁻³ μm²(杨雨等, 2022)。泥质灰岩样品的孔隙度介于 2.00%~8.51%,平均值为 2.7%;渗透率介于(0.001~1.490)×10⁻³ μm²,平均值为 0.190×10⁻³ μm²。总体上属于低孔低渗型储层(杨雨等, 2022)。

在川中地区雷三²亚段中灰岩、泥质灰岩、白云岩及膏盐岩等岩石类型与测井参数之间表现出显著的响应差异,测井响应参数见表 1,交会关系如图 3 所示。不同岩性对应的自然伽马曲线(GR)、声波时差(AC)、密度(DEN)、地层真电阻率(RT)与冲洗带电阻率(RXO)等测井

图 2 川中地区雷三²亚段岩石学特征图Fig. 2 Petrological characteristics of Lei₃²

(A) 灰黑色含泥晶灰岩, 深度 3 567.56~3 567.87 m, CT1 井; (B) 灰黑色富含有机质泥质灰岩, 深度 3 566.61~3 566.80 m, CT1 井; (C) 膏质泻湖相灰白色膏岩, 深度 2 636.27~2 636.50 m, JY1 井; (D) 泥晶灰岩, 溶孔泥质充填, 单偏光, 2.5×, 深度 3 221.56 m, CT1 井; (E) 泥质灰岩, 裂缝部分泥质充填, 单偏光, 5×, 深度 3 563.06 m, CT1 井; (F) 泥质灰岩, 部分溶孔泥质充填, 单偏光, 5×, 深度 3 215.33 m, CT1 井; (G) 含膏泥质灰岩, 方解石脉, 单偏光, 2.5×, 深度 3 222.79 m, CT1 井; (H) 膏盐岩, 沥青侵染, 正交偏光, 5×, 深度 2 636.30 m, JY1 井; (I) 灰质云岩, 裂缝充填白云石, 单偏光, 5×, 深度 2 639.91 m, JY1 井

表 1 四川盆地雷三²亚段岩性-测井特征数据分布表Table 1 Lithology-well-log characteristics data of Lei₃²

岩性	GR/API	AC/($\mu\text{s}\cdot\text{ft}^{-1}$)	CNL/%	DEN/($\text{g}\cdot\text{cm}^{-3}$)	RT/($\Omega\cdot\text{m}$)	RXO/($\Omega\cdot\text{m}$)
泥质灰岩	20.147~68.974	46.543~75.217	0.057~17.159	2.620~2.970	7.115~10 095.081	4.785~4 274.305
	44.651	54.190	7.233	2.696	579.088	313.776
灰岩	20.414~46.604	46.086~50.400	0~6.843	2.726~2.981	220.140~97 832.703	181.362~13 398.665
	29.881	48.710	2.360	2.875	15 462.801	3 793.291
膏盐岩	17.765~59.110	46.666~58.424	0.001~11.586	2.668~2.946	47.934~81 296.063	33.975~9 603.514
	33.092	49.891	3.891	2.786	5 335.914	1 693.175
白云岩	27.622~65.183	49.456~53.505	4.025~14.956	2.678~2.883	66.678~659.437	60.590~449.631
	48.627	51.372	8.194	2.750	213.893	168.426

注: 表格中每种岩性的第一行为数据范围, 第二行加粗数据表示平均值。

参数在多维属性空间中呈现出相对稳定的统计关联。其中, 泥质灰岩具有高 GR、中等 AC、低

密度、低电阻率的特征(表 1)。泥质灰岩的 GR 与 AC 具有线性相关关系, 且斜率 $K=0.967$, 相关




图3 四川盆地雷三²亚段测井-岩性响应交会图
Fig. 3 Well-log-lithological response intersection diagram of Lei₃²

系数 $R^2=0.867$ (图 3-A), 表明其泥质含量较高; 泥质灰岩的 GR 与 DEN, RT 线性关系呈负相关, 相关系数分别为 0.785, 0.755 (图 3-B, C), 表明泥质灰岩的密度相对较低、电阻率较小。灰岩具有中等 GR、中等 AC、中等电阻率的特征 (表 1)。灰岩显示出较强的电阻率响应特征, GR 与 RT 及 RXO 相关系数分别为 0.365, 0.427 (图 3-C, D), 反映其致密和低孔隙度特征; 灰岩的 AC 与 DEN 呈负相关 (相关系数为 0.338) (图 3-E), 与其致密程度变化及局部孔隙发育带有关。白云岩具有低 GR、高密度、高电阻率的特征 (表 1)。白云岩的 AC 与 DEN, RT 表现出正相关特征, 相关系数分别为 0.386 和 0.411 (图 3-E, F)。膏盐岩具有低 GR、高密度的特征 (表 1)。膏盐岩呈现典型的低电阻率响应特征, DEN 与 RT, RXO 正相关, 相关系数为 0.561, 0.453 (图 3-G, H), RT 与 RXO 正相关, 相关系数为 0.598 (图 3-I), 表现出高密度、低电阻率的特征。

3 数据集和预处理

结合测井曲线完整度分析, GR, AC, CNL, DEN, RT 和 RXO 的完整度较高, 分别为 0.99, 0.98, 0.97, 0.93, 0.96 和 0.94; 而 NPHI, RHOB, SP 和 CAL 的完整度相对较低, 分别为 0.58, 0.46, 0.43 和 0.25。基于测井曲线完整度及测井-岩性响应特征 (图 3), 建立川中地区雷三²亚段的测井数据集。选取钻井中覆盖率高、缺失率低、且具有岩性区分敏感性 (图 3)、能够反映放射性、声学、密度及电性响应特征的 6 条曲线, 即 GR, AC, CNL, DEN, RT 和 RXO, 结合取心分析资料, 对川中地区的 102 口钻井进行数据汇总, 共获得深度-测井-岩性标签有效数据 24 899 条。采用相同层位所有井间均值填充方法处理数据缺失值, 对异常值 (包括负值及 Z-score 方法识别的异常点) 进行拟合和转换, 最后采用 Z-score 标准化方法进行数据标准化处理, 使各特征数据均值为 0, 标准差为 1, 保证

特征在同一尺度下输入模型。将标注后的数据集采用滑动窗口法(Hamilton, 1994; Brockwell and Davis, 2002)结合时间序列交叉验证(Bergmeir et al., 2018), 动态划分训练集、验证集, 保留 CT1 井等 13 口岩性类别覆盖较全的典型井(10% 井数据)作为固定测试集, 进行模型检验及评估。

4 机器学习模型建立

长短时记忆循环神经网络模型(LSTM)(Hochreiter and Schmidhuber, 1997), 在循环神经网络(RNN)(Rumelhart et al., 1986)结构中新增遗忘门、输入门、输出门 3 个门控结构并结合激活函数(tanh 与 Sigmoid)的非线性映射机制, 使自循环的权重成为变化的参数(图 4)。其中, f_t 、 i_t 和 o_t 分别代表遗忘门、输入门和输出门, $\tilde{C}_t$ 是候选记忆单元, C_t 即当前的记忆单元状态, x_t 表示 t 时刻的输入, h_t 表示 t 时刻神经元的状态, σ 是 Sigmoid 激活函数, 输出为 $[0, 1]$ 。在每个时间步长 t , 输入 x_t 是一个六维向量, 包含当前深度归一化后的 GR, AC, CNL, DEN, RT 和 RXO 值。

在数据集和预处理的基础上, 利用 LSTM 模型开展岩性预测。LSTM 以时间序列方式逐点接收测井数据输入, 并通过记忆单元实现序列特征的捕捉与传递。预测流程中, 首先对训练完成的模型进行初始化, 输入滑动窗口分割的测井序列, 在每个时间步输出当前深度点的岩性预测结果(逐步预测)。在预测过程中, 上一时刻的隐藏状态和预测结果会作为输入条件参与下一时刻的计算, 实现深度方向的迭代预测, 直至全井段

完成。预测范围覆盖雷三²亚段的全井段深度, 迭代步长与测井数据采样间隔一致(0.125 m)。

在 LSTM 模型中, 遗忘门(公式 1)通过 Sigmoid 函数控制前一时刻单元状态 C_{t-1} 中的信息是否保留, $W_f \in \mathbb{R}^{m \times (m+d)}$, $b_f \in \mathbb{R}^m$ 表示遗忘门参数, 并通过乘积 $f_t \odot C_{t-1}$ 来决定遗忘的比例。对于测井数据, 遗忘门过滤掉早期深度点中不相关或冗余的信息, 聚焦与岩性过渡相关的特征。输入门(公式 2)则通过 Sigmoid 函数输出 i_t , 控制当前时刻的候选记忆信息 $\tilde{C}_t$ (公式 3)的更新程度, $W_i \in \mathbb{R}^{m \times (m+d)}$, $b_i \in \mathbb{R}^m$ 表示输入门参数, $W_c \in \mathbb{R}^{m \times (m+d)}$, $b_c \in \mathbb{R}^m$ 表示候选记忆信息参数, 并通过 tanh 激活函数计算潜在更新, 捕捉测井数据的模式。故当前时刻的单元状态 C_t 由遗忘门和输入门共同决定(公式 4)。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (4)$$

第 4 个交互层为输出门, $W_o \in \mathbb{R}^{m \times (m+d)}$, $b_o \in \mathbb{R}^m$ 表示输出门参数, 输出门决定当前时刻需要输出的测井信息:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t \odot \tanh(C_t) \quad (6)$$

$[h_{t-1}, x_t]$ 表示在特征维上的向量拼接。输入门决定信息保留, LSTM 单元将当前时刻的输入 x_t 和上一时刻的隐藏状态 h_{t-1} 存入候选记忆单元状态 $\tilde{C}_t$ 中, 通过输入门的输出 i_t , 将候选信息 $\tilde{C}_t$ 选择性地加入到记忆单元状态 C_t 中, 与遗忘门的输




图 4 LSTM 模型结构图(修改自 Graves and Schmidhuber, 2005)

Fig. 4 LSTM model structure

出 $f_i \odot C_{t-1}$ 一起更新当前的记忆单元状态 C_t 。

得到当前时刻的记忆单元状态 C_t 后, LSTM 单元计算输出门 o_t (公式 5), 以确定当前时刻的隐藏状态 h_t (公式 6), 并传递到下一个时刻, 完成当前时刻的计算。

5 预测结果

为验证模型有效性, 固定训练过程中的批尺寸 (batchsize) 为 4, 训练的轮数 (epochs) 设置为 100, 利用 LSTM 模型同多类具有代表性的基线模型对比, 包括双向长短时记忆网络 (BiLSTM) (Schuster and Paliwal, 1997)、卷积神经网络-长短时记忆网络 (CNN-LSTM) (Donahue et al., 2015)、卷积神经网络-双向注意力机制-双向长短时记忆网络 (CNN-BiAttention-BiLSTM) (Zhou and Li, 2019) 以及传统机器学习方法即 XGBoost (Chen and Guestrin, 2016)、RF (Breiman, 2001)、SVM (Cortes and Vapnik, 1995) 及 ANN (McCulloch and pitts, 1943) 模型对比。

选取召回率、准确率、精确率、F1 分数、Kappa 系数 5 种常见模型评价指标进行判断 (公式 7~12)。其中, 召回率用于衡量模型识别出真正样本的能力, 准确率反映模型整体预测正确的比例, 精确率表示预测为正样本中真正为正的样本比例, F1 分数作为精确率与召回率的调和平均数, 用于综合评价模型在正负样本上的平衡表现, Kappa 系数则用于度量预测结果与真实结果之间的一致性, 以排除偶然一致的影响。对比结果如表 2 所示, 相同训练参数下 LSTM 模型对川中地区雷三²亚段测井-岩性预测效果呈现优于其他模型。

$$R = \frac{TP}{TP + FN} \tag{7}$$

$$A = \frac{TP + TN}{TP + TN + FP + FN} \tag{8}$$

$$P = \frac{TP}{TP + FP} \tag{9}$$

$$F1 = 2 \times \frac{P \times R}{P + R} \tag{10}$$

$$K = \frac{Po - Pe}{1 - Pe} \tag{11}$$

$$Pe = \frac{(TP + FP)(TP + FN) + (TN + FP)(TN + FN)}{(TP + TN + FP + FN)^2} \tag{12}$$

式中: R 为召回率; A 为准确率; P 为精确率; K 为 Kappa 系数。 TP 为预测为正类且实际为正类的样本数量; FN 为预测为负类但实际为正类的样本数量; TN 为预测为负类且实际为负类的样本数量; FP 为预测为正类但实际为负类的样本数量; Po 为实际观察到的分类一致性; Pe 为根据分类的随机分布计算的偶然一致性。

LSTM 模型在各项指标上均优于其他对比模型, 其中准确率、召回率和 F1 值均达到 0.82 以上, 表现出较好的泛化能力。传统机器学习模型如 SVM, RF, XGBoost 在研究任务中整体表现较弱, 准确率和 F1 值多在 0.65~0.70。主要原因可能在于其在建模过程中无法有效捕捉测井数据的时间序列依赖关系, 且对噪声较为敏感。

深度学习模型如 BiLSTM, CNN-LSTM 等在一定程度上改善了序列建模能力, 但 BiLSTM 在长序列信息传递中存在梯度衰减问题, 而 CNN-LSTM 等复合结构在样本规模有限的情况下容易出现过拟合, 从而导致指标下降。相比之下, LSTM 在序列特征提取、长距离依赖建模和非均质储层识别方面表现更优, 尤其在薄层岩性预测中具有更高的准确性。

表 2 模型评价指标对比
Table 2 Comparison of model evaluation metrics

模型	召回率	准确率	精确率	F1 分数	Kappa 系数
LSTM	0.822	0.822	0.820	0.820	0.754
BiLSTM	0.724	0.724	0.720	0.710	0.608
CNN-LSTM	0.637	0.637	0.636	0.621	0.493
CNN-BiAttention-BiLSTM	0.614	0.614	0.599	0.592	0.446
XGBoost	0.705	0.690	0.685	0.685	0.570
RF	0.695	0.685	0.680	0.680	0.560
SVM	0.670	0.660	0.655	0.650	0.530
ANN	0.540	0.540	0.501	0.459	0.299

ANN 模型在本研究中的表现最差(F1 值仅 0.459), 由于 ANN 结构过于简单, 无法有效建模复杂的时间序列特征, 因此难以完成多类岩性识别任务。

5.1 模型预测结果

绘制准确度/损失曲线、ROC 曲线、混淆矩阵展示模型预测结果(图 5), 训练集损失为 0.299 0, 训练准确度为 87.66%, 未参与训练的验证集损失为 0.472 9, 训练准确度为 82.56%。ROC 曲线通过 AUC(area under the curve)面积(公式 13~15)衡量模型性能, 微平均面积达 0.98; 混淆矩阵预测结果表明模型在某一类别的分类预测准确率最高可达 97%。

$$\text{真正率 } TPR = \frac{TP}{TP + FN} \quad (13)$$

$$\text{假正率 } FPR = \frac{FP}{FP + TN} \quad (14)$$

$$AUC = \int_0^1 TPR(FPR) dFPR \quad (15)$$

5.2 模型验证

川中地区雷三²亚段 CT1 井泥质灰岩主要发育在 5 个深度段, 即 3 576~3 595 m, 3 600~3 623 m, 3 627~3 652 m, 3 658~3 672 m 及 3 681~3 691 m,

累计厚度约为 93 m。泥质灰岩总体发育在雷三²亚段的中下部, 纵向上与膏盐岩呈互层或夹层出现(图 6)。CIFLog 软件的分析程序(CRA)能够计算输出硬石膏含量(ANHY)、白云石含量(DOLO)、方解石含量(LIME)及黏土矿物含量(ILLI)等参数, 实现对矿物成分的定量分析, 从而实现各井段岩性的输出。LSTM 模型以 0.125 m 深度间隔共采集 61 个数据点, 输出岩性预测结果。与 CT1 井镜下薄片鉴定结果对比, LSTM 模型预测的岩性符合率达到(87.3±0.5)%, 显著高于 CIFLog 软件的(73.0±1.0)%。LSTM 模型在泥质灰岩薄层识别和复杂岩性组合区表现出更高的准确性(图 6), 表明基于 LSTM 的机器学习方法能够更有效地捕捉测井数据中的复杂非线性关系, 在川中地区雷三²亚段薄层及非均质储层识别方面优于传统的矿物组分模型。

5.3 单井预测结果

预测结果显示, 川中地区雷三²亚段共 76 口井发育泥质灰岩。南充地区雷三²亚段厚度 142~154 m, 泥质灰岩厚度为 69~93 m, 泥质灰岩储层厚度占比为 44.8%~65.5%。遂宁地区雷三²亚段厚度 42~78 m, 泥质灰岩厚度 18~24 m, 泥




图 5 模型训练与验证结果图

Fig. 5 Model training and validation results

(A) LSTM 模型训练集、验证集准确度随训练次数变化图像; (B) LSTM 模型训练集、验证集累计损失随训练次数变化图像; (C) LSTM 模型训练 ROC 曲线; (D) LSTM 模型训练混淆矩阵

质灰岩储层厚度占比为 30.8%~47.6%。安岳地区雷三²亚段厚度 74~150 m, 泥质灰岩厚度 25~88 m, 泥质灰岩储层厚度占比为 33.8%~65.3%。龙岗地区雷三²亚段厚度 130~155 m, 泥质灰岩厚度 62~89 m, 泥质灰岩储层厚度占比为 47.7%~57.4%。川中地区雷三²亚段厚度 42~155 m, 泥质灰岩厚度 18~93 m, 泥质灰岩储层厚度占比为 30.8%~65.5%(图 7)。

5.4 横向展布特征

南西—北东向的 MX8-CT1-LG12-LG22 连井




图 6 CT1 井测井-岩性预测综合柱状图

Fig. 6 CT1 well-log data-lithology prediction composite histograms

(模型预测结果列内虚线表示与测井解释岩性具有相同分辨率)




图 7 川中地区单井泥质灰岩储层厚度与储地比预测图


Fig. 7 Predicted thickness and reservoir-to-ground ratio of marly limestone reservoirs of single wells in the central Sichuan area

剖面(图 8)显示,川中地区雷三²亚段横向上发育三段式岩性组合类型。第一种是白云岩-泥质灰岩-膏盐岩组合,纵向上发育在雷三²亚段的下部,连井剖面上主要发育在川中北部的 LG22 井区,厚度分别为 7 m, 22 m 和 9 m,指示云坪微相。第二种是膏盐岩-泥质灰岩的组合,纵向上发育在雷三²亚段的中-上部,遍布川中地区,在南东方向的 MX8 厚 71 m, CT1 井厚 142 m, LG12-LG22 井区厚 117~154 m,多指示北东-南西走向的膏盐盆潟湖沉积微相,剖面上呈中心厚、边缘薄的特征。第三种组合类型为灰岩-泥质灰岩的

组合,纵向上发育在雷三²亚段的顶部,连井剖面上仅发育在 MX8 和 LG22 井区,厚度分别为 8 m 和 7 m,指示灰坪微相。

5.5 平面展布特征

利用雷三²亚段 300 余口井测井资料计算的泥质含量、灰质含量、膏质含量、白云质含量做单因素含量(体积分数)分布图(图 9)。结合模型中的岩性分类结果,通过单因素空间分布规律(图 9),进一步提取典型区域的单因素含量范围,形成四川盆地单因素含量分布表(表 3)。四川盆地雷三²亚段的泥质含量呈现由东向西逐渐降低的趋势。

图 8 MX8-CT1-LG12-LG22 井雷三²亚段泥质灰岩储层连井图Fig. 8 MX8, CT1, LG12, and LG22 well composite diagram of the marly limestone reservoir in Lei₃²




图 9 四川盆地雷三²亚段单因素体积分数等值线图
Fig. 9 Contour plots show the single-factor content thicknesses in Lei₃²

(A)四川盆地雷三²亚段泥质体积分数等值线图;(B)四川盆地雷三²亚段灰质体积分数等值线图;(C)四川盆地雷三²亚段膏质体积分数等值线图;(D)四川盆地雷三²亚段云质体积分数等值线图

表 3 四川盆地单因素体积分数分布表
Table 3 Single-factor content distribution in Sichuan Basin

区域	泥质体积分数	灰质体积分数	膏质体积分数	白云质体积分数
川中	遂宁—南充 (60%~80%)	遂宁—南充—广安—合川 (50%~70%)	遂宁—广安 (80%~100%)	资阳—遂宁—南充 (0~10%)
	广安 (20%~40%)	资阳 (40%~60%)		
川东	万州 (70%~90%)	万州 (0~20%)	万州 (20%~40%)	开县—万州 (20%~40%)
川西	威远 (0~20%)	雅安 (0~20%)	雅安—邛崃 (10%~30%)	雅安—邛崃 (50%~70%)
川南	宜宾 (10%~30%)	宜宾 (70%~100%)	宜宾—威远 (0~10%)	涪陵—南川 (20%~40%)
川北	达州 (80%~100%)	德阳—苍溪 (30%~50%)	德阳—苍溪 (10%~30%)	德阳—苍溪 (50%~80%)

川中地区泥质含量呈现“中高边低”的分布规律,泥质含量集中分布于遂宁—南充地区,体积分数范围为60%~80%。灰质高含量区域集中川南宜宾地区,沿宜宾、合川—广安地区减小。川中地

区灰质层沿着南充、遂宁至资阳地区分布,灰质体积分数分布范围为40%~70%。四川盆地膏质的高含量区域集中在中部遂宁—广安区域,局部显示牛眼状分布特征,在乐山—资阳—遂宁一线

与低RT的测井响应特征。LSTM模型与BiLSTM, CNN-LSTM, CNN-BiAttention-BiLSTM, XGBoost, RF, SVM和ANN等方法对比识别精度最高,在整体储层刻画方面取得较好效果,能够有效区分泥质灰岩、灰岩、白云岩及膏盐岩等岩石类型,且在储层空间分布预测中取得较高精度。结合CIFLog软件计算和薄片鉴定验证显示,模型预测的岩性符合率达到 $(87.3\pm 0.5)\%$ 。泥质灰岩储层“中厚边薄”的分布规律与区域沉积背景相吻合,证明了模型预测结果的地质合理性,说明本文方法针对川中地区雷三²亚段的泥质灰岩储层分布预测具有较强的可靠性。现有研究多采用端-端机器学习模型实现测井数据到岩性的直接预测,利用深度循环神经网络、注意力机制、传统机器学习分类器(支持向量机、随机森林、K邻近、人工神经网络)以及小样本条件下的元学习框架进行岩性识别与储层建模,在碳酸盐岩储层中取得一定成果(Zeng et al., 2020; Kumar et al., 2022; Sun et al., 2025; Li et al., 2025)。然而,这些方法忽略了地层在垂向上的时序依赖与沉积旋回对岩性组合的制约作用,难以充分捕捉储层演化过程中的时间序列规律性。本文采用LSTM模型结合单因素分布特征,强调深度序列建模以及地质信息多源制约,更适合捕捉泥质灰岩储层的层序性和复杂性。此外,本文提出的“点-线-面”多元综合预测思路,将单井岩性识别结果拓展至连井剖面和平面向分布,为泥质灰岩储层预测提供了新的系统化技术路径。

然而,研究过程中由于岩心、薄片等岩石学资料与物性数据的不足,导致薄层和快速过渡带区域的边界刻画精度偏低。目前研究的应用范围仅针对于川中地区雷三²亚段,纵向上在其他层段或更深层位以及四川盆地其他地区或其他盆地的泛化能力尚未得到系统验证。但已有研究表明,序列建模在复杂储层识别与预测中具有关键作用,引入注意力机制与多源融合能显著提升岩性识别的精度和稳定性(Chen et al., 2025)。通过在模型中引入物理先验约束(如 Archie 方程、密度-孔隙度关系、矿物体积分解)可减少岩性识别混淆,从而增强预测结果的地质合理性(Pothana and Ling, 2025)。

因此,后续研究可从以下几方面开展:(1)引入注意力机制,在现有LSTM框架基础上增强对

测井曲线不同通道特征的权重分配与序列依赖的捕捉能力,进一步提高复杂岩性组合下的识别精度。(2)融合物理约束与深度学习,通过引入FMI成像、NMR和矿物定量分析等多源资料增强样本约束力,尝试在模型训练中加入物理先验,提高结果的预测精度及地质可解释性。(3)开展迁移学习与不确定性分析,在跨层段、跨区块乃至跨盆地的应用中验证与提升模型的稳定性,对预测结果的不确定性开展量化表征。通过这些改进,有望进一步增强泥质灰岩储层预测的可靠性。

7 结论

a. 川中地区雷三²亚段主要为灰岩、泥质灰岩、白云岩和膏盐岩,泥质灰岩为低孔低渗型储层。泥质灰岩测井响应特征表现为高GR、中等AC、低DEN及RT。泥质灰岩与GR, AC正相关,与DEN, RT, RXO负相关。

b. LSTM模型对川中地区雷三²亚段的岩性识别结果精度可靠,与BiLSTM、CNN-LSTM、CNN-BiAttention-BiLSTM, XGBoost, RF, SVM和ANN模型相比,LSTM模型识别效果最优。对比CIFLog软件计算结果及镜下薄片鉴定结果,LSTM模型预测的岩性符合率达到 $(87.3\pm 0.5)\%$ 。

c. 川中地区雷三²亚段单井泥质灰岩储层占比范围30.8%~65.5%。川中地区泥质含量呈现“中高边低”的分布规律,高泥质含量区域分布于遂宁—南充。西充、南充及仪陇地区为优势勘探区,泥质灰岩储层厚度介于80~120 m。中江、资阳、安岳及合川地区为潜在勘探区,泥质灰岩储层厚度60~80 m。

利益冲突声明: 本文所有作者声明本研究无任何利益冲突。

作者贡献声明: 任杉、宋金民、李柯然、刘树根、王斌论文构思、数据分析、研究方法和论文写作;杨迪、叶玥豪、李泽奇、邵兴鹏参与数据分析和技术手段的实践应用和绘图;周佳庆、杨绍海、闫春桥、金鑫、郭嘉欣参与数据分析、研究方法和修改。所有作者均阅读并同意最终稿件的提交。

[参 考 文 献]

陈科贵,李利,王刚,等,2014. 四川盆地南充盐盆下、中三叠统

- 测井响应特征及成钾条件分析[J]. 矿床地质, 33(5): 1069—1080.
- Chen K G, Li L, Wang G, et al., 2014. Analysis of logging response characteristics and potassium-forming conditions of Early and Middle Triassic strata in Nanchong Basin[J]. Mineral Deposit, 33(5): 1069—1080. (in Chinese)
- 崔正伟, 2021. 基于构造导向滤波与 GST 算法的储层裂缝预测方法研究及应用[D]. 成都: 成都理工大学.
- Cui Z W, 2021. Research and application of reservoir fracture prediction method based on structure-oriented filtering and GST algorithm[D]. Chengdu: Chengdu University of Technology. (in Chinese)
- 谷宇峰, 张道勇, 鲍志东, 等, 2021. GBDT 识别致密砂岩储层岩性[J]. 地球物理学进展, 36(5): 1956—1965.
- Gu Y F, Zhang D Y, Bao Z D, et al., 2021. Lithology prediction of tight sandstone reservoirs using GBDT[J]. Progress in Geophysics, 36(5): 1956—1965. (in Chinese)
- 江凯, 王守东, 胡永静, 等, 2018. 基于 Boosting Tree 算法的测井岩性识别模型[J]. 测井技术, 42(4): 395—400.
- Jiang K, Wang S D, Hu Y J, et al., 2018. Lithology identification model by well logging based on boosting tree algorithm[J]. Well Logging Technology, 42(4): 395—400. (in Chinese)
- 蒋旭东, 2021. 川西深层雷口坡组碳酸盐岩储层含气性预测方法研究[D]. 成都: 成都理工大学.
- Jiang X D, 2021. Study on hydrocarbon detection method for carbonate rocks in deep Leikoupo Formation of Western Sichuan[D]. Chengdu: Chengdu University of Technology. (in Chinese)
- 孔强夫, 杨才, 李浩, 等, 2020. 基于图论聚类和最小临近算法的岩性识别方法——以四川盆地西部雷口坡组碳酸盐岩储层为例[J]. 石油与天然气地质, 41(4): 884—890.
- Kong Q F, Yang C, Li H, et al., 2020. A lithology recognition method based on multi-resolution graph-based clustering and K-Nearest Neighbor: A case study from the Leikoupo Formation carbonate reservoirs in western Sichuan Basin[J]. Oil & Gas Geology, 41(4): 884—890. (in Chinese)
- 刘树根, 孙玮, 宋金民, 等, 2019. 四川盆地中三叠统雷口坡组天然气勘探的关键地质问题[J]. 天然气地球科学, 30(2): 151—167.
- Liu S G, Sun W, Song J M, et al., 2019. The key geological problems of natural gas exploration in the Middle Triassic Leikoupo Formation in Sichuan Basin[J]. Natural Gas Geoscience, 30(2): 151—167. (in Chinese)
- 罗仁泽, 庾娟娟, 倪华玲, 等, 2023. 基于改进集成学习的测井岩性识别方法研究[J]. 石油物探, 62(2): 212—224.
- Luo R Z, Tuo J J, Ni H L, et al., 2023. Logging lithology identification method based on improved ensemble learning[J]. Geophysical Prospecting for Petroleum, 62(2): 212—224. (in Chinese)
- 秦川, 2009. 川中南部地区中三叠统雷口坡组储层特征[D]. 成都: 成都理工大学.
- Qin C, 2009. Reservoir characteristics of Middle Triassic Leikoupo Formation in the Southern part of central Sichuan Basin[D]. Chengdu: Chengdu University of Technology. (in Chinese)
- 秦小林, 古徐, 李弟诚, 等, 2025. 大语言模型综述与展望[J]. 计算机应用, 45(3): 685—696.
- Qin X L, Gu X, Li D C, et al., 2025. Survey and prospect of large language models[J]. Journal of Computer Applications, 45(3): 685—696. (in Chinese)
- 阮蕴博, 周刚, 霍飞, 等, 2022. 川中地区中三叠统雷口坡组三段源储特征及配置关系[J]. 岩性油气藏, 34(5): 139—151.
- Ruan Y B, Zhou G, Huo F, et al., 2022. Source-reservoir characteristics and configuration of the third member of Middle Triassic Leikoupo Formation in central Sichuan Basin[J]. Lithologic Reservoirs, 34(5): 139—151. (in Chinese)
- 宋金民, 刘树根, 李智武, 等, 2024. 川西地区中三叠统雷口坡组四段古海湾特征及其油气地质意义[J]. 石油勘探与开发, 51(6): 1291—1303.
- Song J M, Liu S G, Li Z W, et al., 2024. Characteristics and hydrocarbon geological significances of paleo-bay in the fourth member of Middle Triassic Leikoupo Formation, western Sichuan Basin, SW China[J]. Petroleum Exploration and Development, 51(6): 1291—1303. (in Chinese)
- 宋晓波, 刘勇, 隆轲, 等, 2024. 川西新场地区中三叠统雷口坡组气藏天然气来源[J]. 天然气地球科学, 35(12): 2121—2131.
- Song X B, Liu Y, Long K, et al., 2024. Gas source of the Middle Triassic Leikoupo Formation gas reservoir in Xinchang area of western Sichuan Basin, China[J]. Natural Gas Geoscience, 35(12): 2121—2131. (in Chinese)
- 孙豪飞, 罗冰, 文龙, 等, 2021. 四川盆地雷口坡组富有机质页岩的发现及盐下勘探新领域[J]. 天然气地球科学, 32(2): 233—247.
- Sun H F, Luo B, Wen L, et al., 2021. The first discovery of organic-rich shale in Leikoupo Formation and new areas of sub salt exploration, Sichuan Basin[J]. Natural Gas Geoscience, 32(2): 233—247. (in Chinese)
- 田瀚, 王贵文, 段书府, 等, 2021. 四川盆地中三叠统雷口坡组储层特征及勘探方向[J]. 中国石油勘探, 26(5): 60—73.
- Tian H, Wang G W, Duan S F, et al., 2021. Reservoir characteristics and exploration target of the Middle Triassic Leikoupo Formation in Sichuan Basin[J]. China Petroleum Exploration, 26(5): 60—73. (in Chinese)
- 汪泽成, 辛勇光, 谢武仁, 等, 2023. 川中地区三叠系雷口坡组泥灰岩油气地质特征及充探 1 井发现意义[J]. 石油勘探与开发, 50(5): 950—961.

- Wang Z C, Xin Y G, Xie W R, et al., 2023. Petroleum geology of marl in Triassic Leikoupo Formation and discovery significance of Well Chongtan1 in central Sichuan Basin, SW China[J]. *Petroleum Exploration and Development*, 50(5): 950—961. (in Chinese)
- 谢武仁, 文龙, 汪泽成, 等, 2024. 四川盆地二叠系—中三叠统海相非常规资源类型及有利勘探方向[J]. *天然气地球科学*, 35(6): 961—971.
- Xie W R, Wen L, Wang Z C, et al., 2024. Types of unconventional marine resources and favorable exploration directions in the Permian-Middle Triassic of the Sichuan Basin[J]. *Natural Gas Geoscience*, 35(6): 961—971. (in Chinese)
- 辛勇光, 文龙, 张豪, 等, 2022. 四川盆地中三叠统雷口坡组储层特征与勘探领域探讨[J]. *中国石油勘探*, 27(4): 91—102.
- Xin Y G, Wen L, Zhang H, et al., 2022. Study on reservoir characteristics and exploration field of the Middle Triassic Leikoupo Formation in Sichuan Basin[J]. *China Petroleum Exploration*, 27(4): 91—102. (in Chinese)
- 杨雨, 谢继容, 张建勇, 等, 2022. 四川盆地中部中三叠统雷三²亚段非常规储层特征及勘探潜力[J]. *天然气工业*, 42(12): 12—22.
- Yang Y, Xie J R, Zhang J Y, et al., 2022. Characteristics and exploration potential of unconventional Middle Triassic Lei₃² reservoirs in the central Sichuan Basin[J]. *Natural Gas Industry*, 42(12): 12—22. (in Chinese)
- 尹宏, 郑超, 王旭丽, 等, 2024. 川西南部地区雷口坡组天然气成藏条件及主控因素[J]. *断块油气田*, 31(6): 959—967.
- Yin H, Zheng C, Wang X L, et al., 2024. Conditions and main controlling factors of natural gas accumulation of Leikoupo Formation in southwestern Sichuan Basin[J]. *Fault-Block Oil & Gas Field*, 31(6): 959—967. (in Chinese)
- 张本健, 孙豪飞, 罗强, 等, 2023. 川中雷口坡组台地潟湖相烃源岩地球化学特征及油气来源[J]. *天然气工业*, 43(6): 15—29.
- Zhang B J, Sun H F, Luo Q, et al., 2023. Geochemical characteristics and hydrocarbon origin of Leikoupo Formation platform lagoon facies shale in central Sichuan Basin[J]. *Natural Gas Industry*, 43(6): 15—29. (in Chinese)
- 张豪, 辛勇光, 马华灵, 等, 2024. 川中充西地区雷三²亚段泥灰岩储层精细预测研究[J]. *成都理工大学学报(自然科学版)*, 51(2): 247—257.
- Zhang H, Xin Y G, Ma H L, et al., 2024. Study on the fine prediction of a marlstone reservoir in the Lei₃² sub-member in Chongxi area, central Sichuan[J]. *Journal of Chengdu University of Technology (Science & Technology Edition)*, 51(2): 247—257. (in Chinese)
- 张豪, 辛勇光, 徐唱, 等, 2023. 川中地区雷三²亚段“灰质岩类”储层主控因素及有利区预测[J]. *天然气勘探与开发*, 46(4): 123—132.
- Zhang H, Xin Y G, Xu C, et al., 2023. Influential factors and prospects on calcareous reservoirs of Lei₃² submember, central Sichuan Basin[J]. *Natural Gas Exploration and Development*, 46(4): 123—132. (in Chinese)
- 张建勇, 辛勇光, 张豪, 等, 2023. 一种新的非常规天然气藏类型——川中地区雷三²亚段蒸发潟湖源储—体碳酸盐岩气藏[J]. *天然气地球科学*, 34(1): 23—34.
- Zhang J Y, Xin Y G, Zhang H, et al., 2023. A new unconventional gas reservoir type: Source-reservoir integrated carbonate gas reservoir from evaporated lagoon facies in Lei₃² submember in Central Sichuan Basin[J]. *Natural Gas Geoscience*, 34(1): 23—34. (in Chinese)
- Bergmeir C, Hyndman R J, Koo B, 2018. A note on the validity of cross-validation for evaluating autoregressive time series prediction[J]. *Computational Statistics & Data Analysis*, 120: 70—83.
- Breiman L, 2001. Random forests[J]. *Machine Learning*, 45(1): 5—32.
- Brockwell P J, Davis R A, 2002. Introduction to time series and forecasting[M]. New York: Springer.
- Chen J, Gui Z, Rui Y C, et al., 2025. A dual attention-based deep learning model for lithology identification while drilling[J/OL]. *Journal of Rock Mechanics and Geotechnical Engineering*, [2025-08-14]. <https://doi.org/10.1016/j.jrmge.2025.03.051>.
- Chen T Q, Guestrin C, 2016. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: Association for Computing Machinery: 785—794.
- Cortes C, Vapnik V, 1995. Support-vector networks[J]. *Machine Learning*, 20(3): 273—297.
- Donahue J, Hendricks L A, Guadarrama S, et al., 2015. Long-term recurrent convolutional networks for visual recognition and description[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE: 2625—2634.
- Graves A, Schmidhuber J, 2005. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. *Neural Networks*, 18(5—6): 602—610.
- Hamilton J D, 1994. Time series analysis[M]. Princeton: Princeton University Press.
- Haritha D, Satyavani N, Ramesh A, 2025. Generation of missing well log data with deep learning: CNN-Bi-LSTM approach[J]. *Journal of Applied Geophysics*, 233: 105628.
- Hochreiter S, Schmidhuber J, 1997. Long short-term memory[J]. *Neural Computation*, 9(8): 1735—1780.

- Kuang L C, Liu H, Ren Y L, et al., 2021. Application and development trend of artificial intelligence in petroleum exploration and development[J]. *Petroleum Exploration and Development*, 48(1): 1—14.
- Kumar T, Seelam N K, Rao G S, et al., 2022. Lithology prediction from well log data using machine learning techniques: A case study from Talcher coalfield, Eastern India[J]. *Journal of Applied Geophysics*, 199: 104605.
- Li H X, Sun Y Z, Qiao S B, et al., 2025. Enhanced lithology identification with few-shot well-logging data using a confidence-enhanced semi-supervised meta-learning approach[J]. *Measurement*, 247: 116762.
- Li S Y, Jin X Y, Xuan Y, et al., 2019. Enhancing the locality and breaking the memory bottleneck of transformer on time series forecasting[C]//*Advances in Neural Information Processing Systems*. Vancouver: Curran Associates.
- Liu B, Yasin Q, Sohail G M, et al., 2023. Seismic characterization of fault and fractures in deep buried carbonate reservoirs using CNN-LSTM based deep neural networks[J]. *Geoenergy Science and Engineering*, 229: 212126.
- Mcculloch W S, Pitts W, 1943. A logical calculus of the ideas immanent in nervous activity[J]. *Bulletin of Mathematical Biophysics*, 5: 115—133.
- Pothana P, Ling K G, 2025. Physics-integrated neural networks for improved mineral volumes and porosity estimation from geophysical well logs[J]. *Energy Geoscience*, 6(2): 100410.
- Rumelhart D E, Hinton G E, Williams R J, 1986. Learning representations by back-propagating errors[J]. *Nature*, 323(6088): 533—536.
- Schuster M, Paliwal K K, 1997. Bidirectional recurrent neural networks[J]. *IEEE Transactions on Signal Processing*, 45(11): 2673—2681.
- Sun Y Z, Pang S C, Qiu Z H, et al., 2025. Efficient lithology classification from small-sample well logging data processed by wavelet thresholding algorithm: Integrating meta-learning with self-attention mechanism model[J]. *Geoenergy Science and Engineering*, 246: 213629.
- Zeng L L, Ren W J, Shan L Q, et al., 2020. Attention-based bidirectional gated recurrent unit neural networks for well logs prediction and lithology identification[J]. *Neurocomputing*, 414: 153—171.
- Zhang M Z, Jia A L, Lei Z X, et al., 2024. Inter-well reservoir parameter prediction based on LSTM-attention network and sedimentary microfacies[J]. *Geoenergy Science and Engineering*, 235: 212723.
- Zhou W, Li Y, 2019. Dual attention network for visual question answering[C]//*Proceedings of the IEEE/CVF International Conference on Computer Vision*. Seoul: IEEE: 6268—6277.
- Zou Y H, Chen Y T, Deng H, 2021. Gradient boosting decision tree for lithology identification with well logs: A case study of Zhaoxian gold deposit, Shandong peninsula, China[J]. *Natural Resources Research*, 30(5): 3197—3217.